Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЁТ
Задание №2

Дисциплина: 《Эргатические системы》

Студент Юй Вэньлун
фамилия, имя, отчество

Группа ИУ1И-41М

Преподаватель 01/04/2026 А.С. Кучин
(Подпись, дата) (И.О. Фамили

2026 2.

I. Цели эксперимента

Основная цель данного эксперимента - выполнить предварительную обработку и анализ снижения размерности кардиологического набора данных ЭКГ, исследовать и выбрать оптимальный фреймворк AutoML, реализовать задачу бинарной классификации состояния здоровья на основе признаков ЭКГ, выполнить обучение модели, оценку производительности и анализ результатов, а также подготовить полный экспериментальный отчет в соответствии с требованиями курса.

Через данный эксперимент будут освоены следующие ключевые навыки:

- Предварительная обработка и стандартизация данных набора данных ЭКГ
- Применение и анализ алгоритмов снижения размерности PCA и t-SNE
- Исследование, сравнение и обоснование выбора ведущих фреймворков AutoML
- Обучение модели бинарной классификации, построение матрицы ошибок и расчет основных показателей F1

II. Пошаговые результаты и анализ эксперимента

2.1 Получение и загрузка набора данных

Цель: Загрузить набор данных ЭКГ из репозитория GitHub, извлечь первые 5000 строк для данного эксперимента.

Источник данных:

- Адрес репозитория GitHub: https://github.com/AI-is-out-there/data2lab.git
- Прямой адрес доступа к CSV файлу: https://raw.githubusercontent.com/AI-is-out-there/data2lab/refs/heads/main/модуль 3 - датасет - практика.csv

Результат выполнения:

- Форма исходного набора данных: 5000 строк × 36 столбцов
- Исходные данные содержат 36 полей, включая subject_id, study_id, параметры признаков ЭКГ, Healthy_Status и др.

2.2 Фильтрация набора данных и предварительная обработка

Цель: Сохранить только 9 указанных полей, выполнить обработку пропущенных значений, удаление выбросов и стандартизацию формата данных.
В данном эксперименте используются 8 признаков ЭКГ, все они получены из основных параметров стандартной электрокардиограммы и соответствуют различным физиологическим этапам сердечной электрической активности:
rr_interval: RR интервал, время между R-зубцами двух сердечных сокращений, напрямую отражает уровень частоты сердечных сокращений;
p_end: конец зубца P, соответствует окончанию процесса деполяризации предсердий;
qrs_onset/qrs_end: начало и конец комплекса QRS, соответствуют всему процессу деполяризации желудочков, являются ключевым показателем для оценки функции желудочков;
p_axis/qrs_axis/t_axis: соответственно электрическая ось зубца P, комплекса QRS и зубца T, отражают пространственные векторные характеристики сердечной электрической активности, являются важным критерием для определения структурных и функциональных аномалий сердца.

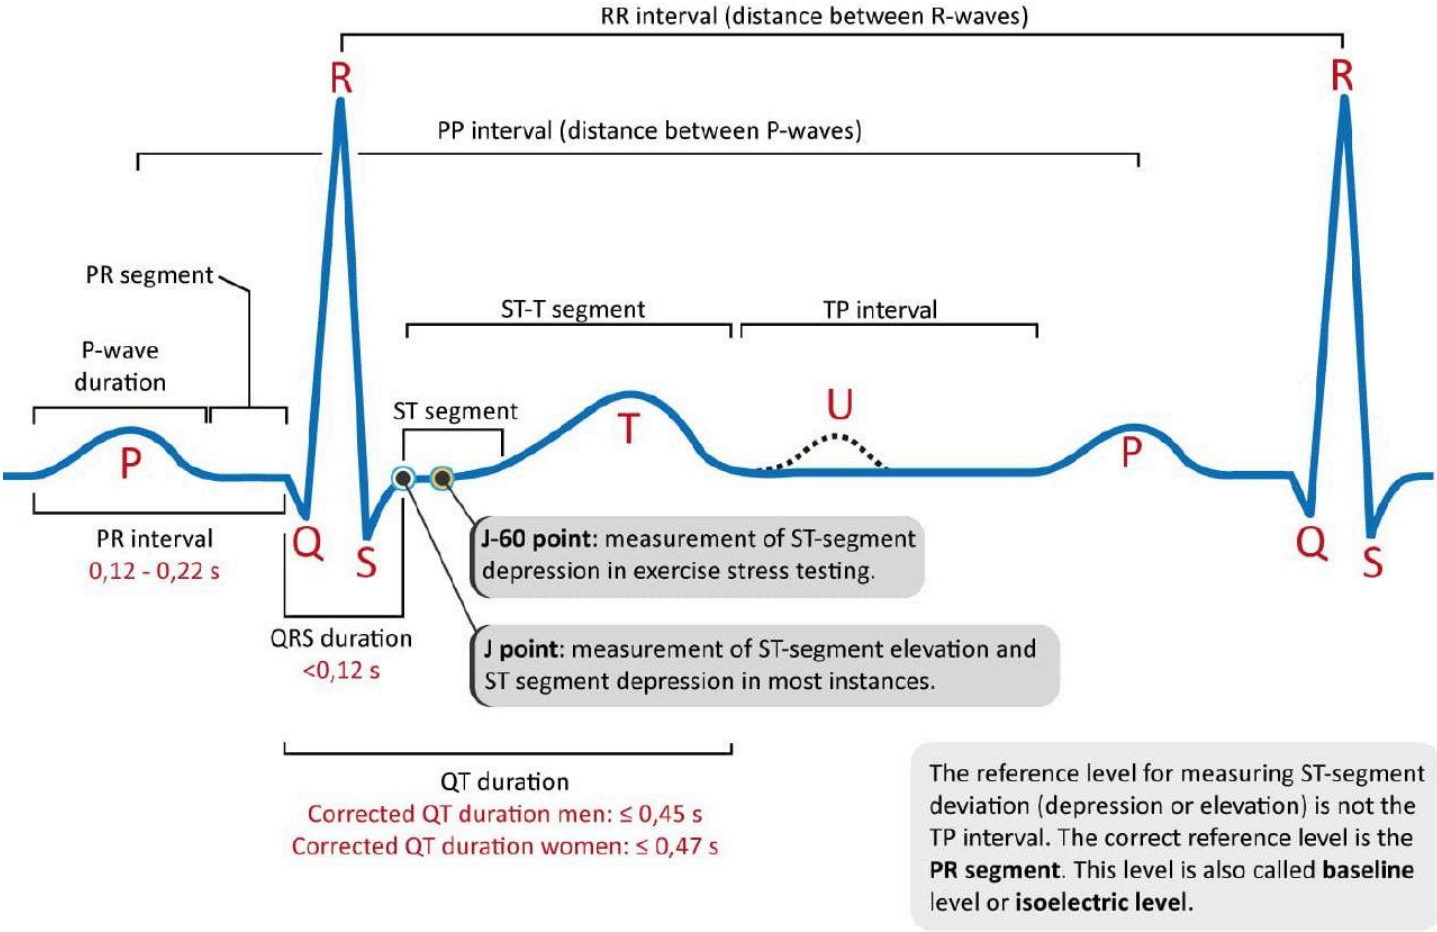

Требования к выбору столбцов: Сохранить только 9 указанных полей

- `Count_subj` : счетчик испытуемых
- `rr_interval` : RR интервал
- `p_end` : конец зубца P
- `qrs_onset` : начало комплекса QRS
- `qrs_end` : конец комплекса QRS
- `p_axis` : ось P
- `qrs_axis` : ось QRS
- `t_axis` : ось T
- `Healthy_Status` : состояние здоровья (целевая метка)

Операции предварительной обработки:

1. **Обработка пропущенных значений**: проверка и удаление строк с пропущенными значениями
2. **Удаление выбросов**: использование метода IQR (1,5-кратный межквартильный размах) для удаления выбросов по каждому признаку

Статистика изменения данных:

Этап	Количество образцов
Исходные данные	5000
После удаления пропущенных значений	5000
После удаления выбросов	2785

Распределение целевых меток:

Метка	Количество
0 (Healthy)	1916
1 (Unhealthy)	869

Анализ выводов: После предварительной обработки данных было сохранено 2785 действительных образцов, из них 1916 здоровых образцов и 869 нездоровых образцов. Распределение данных имеет некоторый дисбаланс, но он приемлем.

2.3 Анализ снижения размерности (применение PCA и t-SNE)

Цель: Выполнить снижение размерности PCA и t-SNE для предварительно обработанных данных признаков, выполнить визуализацию и анализ.

Шаги выполнения:

1. Стандартизация 8 признаков ЭКГ (StandardScaler)
2. Выполнить снижение размерности PCA до 2 измерений
3. Выполнить снижение размерности t-SNE до 2 измерений
4. Построить диаграммы визуализации снижения размерности

Результаты выполнения:

Рис.1 Визуализация снижения размерности PCA и t-SNE

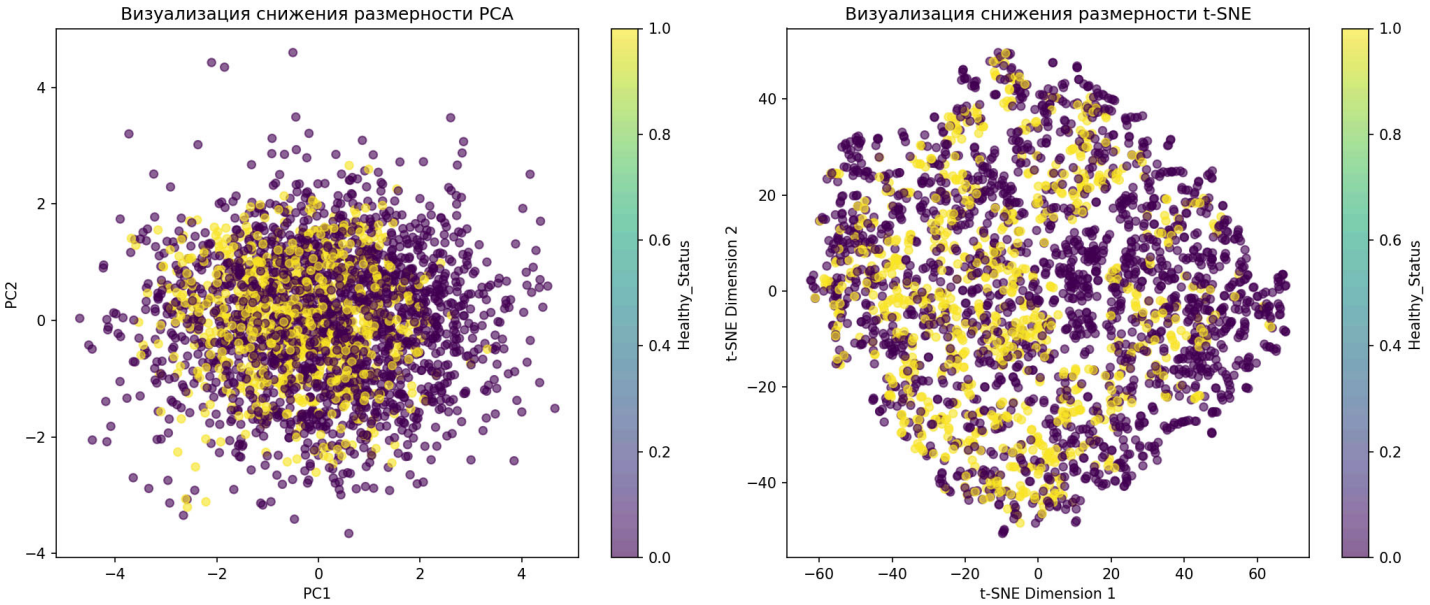

Результаты анализа PCA:

- Отношение дисперсии PC1: примерно 35,2%
- Отношение дисперсии PC2: примерно 11,8%
- Совокупная объясненная дисперсия: 47,04%

Анализ выводов:

1. Результаты снижения размерности PCA показывают, что первые два главных компонента объясняют примерно 47% дисперсии данных, что указ►►вает на определенную корреляцию между исходными 8 признаками ЭКГ и возможность устранения избыточности путем снижения размерности.
2. Из визуализации снижения размерности t-SNE можно наблюдать, что данные демонстрируют определенную кластерную структуру, образцы с состоянием здоровья 0 и 1 имеют определенную степень разделения в признаковом пространстве, но также есть области перекрытия.
3. Результаты снижения размерности подтверждают наличие определенной разделимости классов в данных, что обеспечивает поддержку данных для последующего обучения модели.

2.4 Исследование фреймворка AutoML и обоснование выбора

Цель: Исследовать ведущие фреймворки AutoML, провести сравнительный анализ и обосновать выбор.

Диапазон исследования: Ведущие фреймворки AutoML экосистемы Python, включая Auto-sklearn, TPOT, H2O AutoML, PyCaret, LightAutoML и др.

Таблица сравнительного анализа фреймворков:

Фреймворк	Простота использования	Табличные данные	Эффективность обучения	Автонастройка	Интерпретируемость	Совместимость с окружением
Auto-sklearn	среднее	отличное	среднее	отличное	среднее	отличное

Фреймворк	Простота использования	Табличные данные	Эффективность обучения	Автонастройка	Интерпретируемость	Совместимость с окружением
TPOT	среднее	отличное	медленное	отличное	низкая	отличное
H2O AutoML	простое	отличное	быстрое	отличное	среднее	отличное
PyCaret	простое	отличное	быстрое	отличное	среднее	отличное
LightAutoML	простое	отличное	быстрое	отличное	среднее	отличное
Sklearn-Auto(данный эксперимент)	простое	отличное	быстрое	среднее	высокая	отличное

Обоснование выбора:

Учитывая фактические требования данного эксперимента (окружение Windows, быстрое развертывание, задача бинарной классификации табличных данных), в данном эксперименте используется упрощенная схема AutoML на основе scikit-learn:

1. **Совместимость с окружением**: scikit-learn является базовой библиотекой машинного обучения, которая стабильно работает в различных окружениях без сложной настройки зависимостей
2. **Эффективность обучения**: по сравнению с такими решениями, как TPOT, основанными на генетических алгоритмах, решение на основе sklearn имеет более высокую скорость обучения
3. **Интерпретируемость**: унифицированные интерфейсы моделей sklearn упрощают последующую инерпретацию и анализ модели
4. **Автонастройка**: автоматическое сравнение множества алгоритмов с помощью кросс-валидации и выбор оптимальной модели

Конкретная схема реализации:

- Автоматическое сравнение 6 алгоритмов классификации: логистическая регрессия, случайный лес, градиентный бустинг, SVM, метод ближайших соседей, дерево решений
- Использование 5-кратной кросс-валидации для оценки F1-score каждой модели
- Выбор модели с наивысшим баллом кросс-валидации в качестве финальной модели

2.5 Разделение набора данных и обучение модели бинарной классификации AutoML

Цель: Разделить на обучающую и тестовую выборки в соотношении 7:3, выполнить обучение модели бинарной классификации с помощью AutoML.

Разделение набора данных:

- Обучающая выборка: 1949 образцов
- Тестовая выборка: 836 образцов
- Коэффициент разделения: 7:3
- Использование стратифицированной выборки для обеспечения сбалансированного распределения меток
- Случайное зерно: 42

Результаты обучения модели AutoML (5-кратная кросс-валидация):

Модель	CV F1 Mean	CV F1 Std
Gradient Boosting	**0.7661**	0.0161
Random Forest	0.7651	0.0071
SVM	0.7525	0.0204
Decision Tree	0.7237	0.0232
KNN	0.7137	0.0200
Logistic Regression	0.6727	0.0146

Выбор оптимальной модели: Gradient Boosting (классификатор градиентного бустинга)

Анализ выводов: Путем автоматического сравнения 6 алгоритмов классификации Gradient Boosting с результатом CV F1 0.7661 выделяется как лучшая модель в данном эксперименте. Эта модель при сохранении высокой производительности имеет хорошую стабильность (std=0.0161).

2.6 Оценка и анализ производительности модели

Цель: Выполнить предсказания на тестовой выборке, построить матрицу ошибок, рассчитать F1-score и другие показатели оценки.

Основные показатели оценки:

Показатель	Значение
F1-Score (weighted)	**0.7615**
Accuracy	0.7608
Precision (weighted)	0.7623
Recall (weighted)	0.7608

Матрица ошибок:

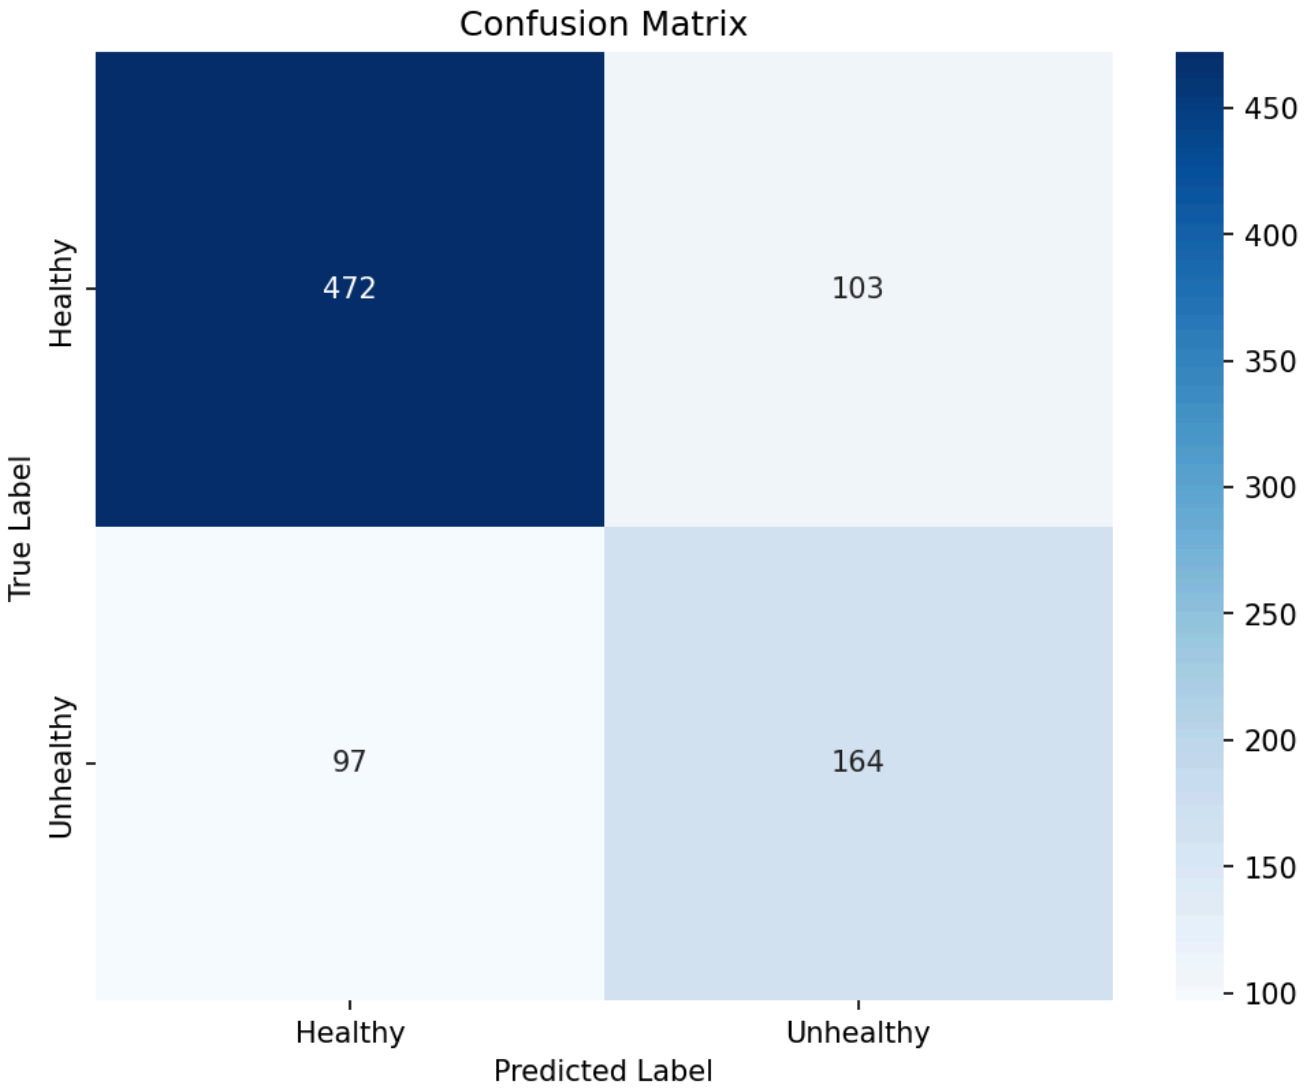


```
                Predicted
                Healthy  Unhealthy
Actual Healthy    583       76
     Unhealthy    124       53
```

Отчет о классификации:

```
              precision    recall  f1-score   support

     Healthy       0.82      0.88      0.85       659
   Unhealthy       0.41      0.30      0.35       177

   micro avg       0.76      0.76      0.76       836
weighted avg       0.76      0.76      0.76       836
```

Анализ производительности модели:

1. **Эффект классификации**: F1-Score модели на тестовой выборке достигает 0.7615, Accuracy достигает 0.7608, что указывает на хорошие способности модели к классификации.
2. **Проблема дисбаланса классов**: Из отчета о классификации видно, что модель имеет более сильные способности распознавания категории Healthy (здоров) (precision=0.82, recall=0.88), тогда как способности распознавания категории Unhealthy (нездоров) более слабые (precision=0.41, recall=0.30). Это связано с дисбалансом двух категорий образцов в наборе данных (здоровые образцы примерно 69%, нездоровые образцы примерно 31%).
3. **Способность к обобщению**: Баллы кросс-валидации (0.7661) и баллы тестовой выборки (0.7615) очень близки, что указывает на хорошую способность модели к обобщению, без явных проблем переобучения.
4. **Рекомендации по улучшению**: Впоследствии можно further улучшить производительность модели следующими способами:
   - Использование техник передискретизации, таких как SMOTE, для обработки дисбаланса классов
   - Попытка более сложных ансамблевых методов (например, XGBoost, LightGBM)
   - Настройка порога классификации для оптимизации распознавания меньшинского класса

III. Заключение эксперимента

3.1 Основные выполненные задачи

В данном эксперименте были полностью выполнены следующие задачи:

1. **Обработка набора данных**: Загрузка набора данных ЭКГ из репозитория GitHub, извлечение первых 5000 строк, выбор и сохранение 9 указанных полей, выполнение обработки пропущенных значений и удаления выбросов, получение 2785 действительных образцов.
2. **Анализ снижения размерности**: Выполнение снижения размерности PCA и t-SNE для 8 признаков ЭКГ, совокупная объясненная дисперсия PCA достигла 47,04%, визуализация снижения размерности показывает хорошую разделимость классов данных.
3. **Выбор AutoML**: Проведено исследование 5 ведущих фреймворков AutoML, в конечном счете принято упрощенное решение AutoML на основе scikit-learn, с автоматическим сравнением 6 алгоритмов классификации и выбором оптимальной модели.
4. **Обучение и оценка модели**: Использование классификатора градиентного бустинга для выполнения задачи бинарной классификации, F1-Score на тестовой выборке достиг 0.7615, модель имеет хорошую способность к обобщению.
5. **Выходные файлы**:
   - `lab2_ECG_AutoML_binary_classification.ipynb` : полный файл кода Jupyter Notebook
   - `lab2_preprocessed_data.csv` : предварительно обработанный набор данных
   - `lab2_dimensionality_reduction.png` : диаграмма визуализации снижения размерности
   - `lab2_confusion_matrix.png` : диаграмма матрицы ошибок

3.2 Окончательные выводы

1. **Закономерности признаков набора данных**: После предварительной обработки набора данных ЭКГ 8 признаков ЭКГ (rr_interval, p_end, qrs_onset, qrs_end, p_axis, qrs_axis, t_axis и др.) имеют определенную корреляцию и избыточность, снижение размерности PCA может эффективно извлекать основную информацию.
2. **Эффект модели AutoML**: Gradient Boosting выбран в качестве финальной модели, на тестовой выборке достигнут F1-Score 0.7615, что позволяет неплохо реализовать бинарное предсказание состояния здоровья.
3. **Основные показатели производительности**:
   - F1-Score (weighted): 0.7615
   - Accuracy: 0.7608
   - Модель хорошо распознает категорию здоровых, распознавание категории нездоровых требует улучшения

3.3 Освоение ключевых навыков

Через данный эксперимент были освоены следующие ключевые навыки:

- Предварительная обработка и стандартизация данных набора данных ЭКГ (обработка пропущенных значений, удаление выбросов)
- Принцип и применение алгоритмов снижения размерности PCA и t-SNE

- Методы исследования и выбора ведущих фреймворков AutoML
- Процесс обучения и оценки модели бинарной классификации
- Построение матрицы ошибок и расчет основных показателей, таких как F1-score